Análise e entendimento dos dados

Introdução
Visão Geral dos Datasets (Interpretação)
- kc_house_data
- zipcode_demographic
- Observações Iniciais

Mesclando os datasets (merge)
Visualização dos dados e observações
- Assimetria dos Dados
- Outliers
- Correlação

Importância das Features

Introdução

Este documento tem como objetivo dar uma visão geral da análise de dados empreendida na solução do "**Desafio de Data Science — Previsão de Preços de Casas**".

As análises feitas tem como base o notebook em `notebook/eda-visualization-feature-sel-eng-baseline.ipynb`, onde foi feita:

- Análise preliminar dos datasets fornecidos
  - Tamanho e qualidade do dataset: quantidade de linhas e colunas, existência de valores nulos, tipos de dados de cada atributo,
  - Entendimento de cada dataset
  - Detecção da variável alvo
  - Análise da relação semântica entre as colunas tendo em vista a variável alvo
- Merge dos dois datasets
- Visualização dos dados

    - Distribuição dos dados
    - Boxplots para aferir a presença de outliers
    - Matriz de correlação
    - Correlação das colunas em relação à variável alvo
- Verificação das importância das features
    - Utilização de `LassoCV` para a detecção das variáveis mais importantes para a modelagem linear (aproximação linear da função)
- Treinamento do baseline - Regressão Linear
    - Verificação das métricas

Visão Geral dos Datasets (Interpretação)

Para a solução do problema, foram fornecidos dois datasets, `kc_house_data.csv` e `zipcode_demographics.csv`.

kc_house_data

Contém atributos relativos às características físicas das casas/imóveis, sua localização em latitude e longitude, zip code, variáveis temporais, e seu preço, que é a nossa variável alvo.

Dentre as principais variáveis podemos listar:

- `price`: preço atual da casa, ou preço de quando foi vendida, é a variável alvo que queremos prever;
- `waterfront`: se a casa tem vista para a água. É uma variável binária;
- `grade`: qualidade da construção da casa, variando de 1 a 13;
- `sqft_living`: área construída da casa;
- `sqft_living15`: área construída média das 15 casas mais próximas;
- `sqft_above`: área construída acima do solo;
- `yr_renovated`: ano da última reforma da casa. Se a casa nunca foi reformada, o valor é 0;

- `zipcode`: CEP da casa;
- `lat`: latitude da casa;
- `long`: longitude da casa;

zipcode_demographic

Contém características socioeconômicas por região (zipcode). Possui valores absolutos e percentuais. Como o valor percentual já indica a prevalência de um grupo dentro do total populacional, sempre que possível vamos usar os valores percentuais.

Dentre as principais variáveis podemos listar:

- `medn_incm_per_prsn_amt`: renda média por pessoa;
- `per_bchlr`: percentual de pessoas com diploma de bacharel;
- `per_prfsnl`: percentual de pessoas com formação profissional/pós-graduação;
- `per_less_than_9`: percentual de pessoas com menos de 9 anos de escolaridade;
- `per_9_to_12`: percentual de pessoas com 9 a 12 anos de escolaridade;
- `per_some_clg`: percentual de pessoas com alguns anos de faculdade;
- `ppltn_qty`: quantidade total de população na região;
- `farm_ppltn_qty`: quantidade de população rural;
- `urbn_ppltn_qty`: quantidade de população urbana;
- `zipcode`: “CEP” da região;

Observações Iniciais

Uma análise rápida inicial nos permite concluir que o principal dataset é aquele que contém as características físicas das casas/imóveis, e que contém a variável alvo. Queremos fazer com que o algoritmo de regressão aprenda a aproximar uma função que explique os atributos e seja capaz de predizer o valor da variável alvo.

Em segunda análise, o dataset de informações geográficas também contém informações valiosas para a determinação do preço das casas de uma região, dadas as premissas que:

1. Especialmente o meio urbano, é dividido entre bairros e regiões nobres e populares, e que bairros nobres possuem casas de valor elevado;

- Pessoas com formações profissionais e acadêmicas elevadas, geralmente, possuem renda mais elevada do que àquelas que são menos qualificadas academicamente e profissionalmente;

A primeira premissa se confirma no gráfico de “Preço médio das casas por zipcode”, mostrando determinadas área concentram casos de maior valor:

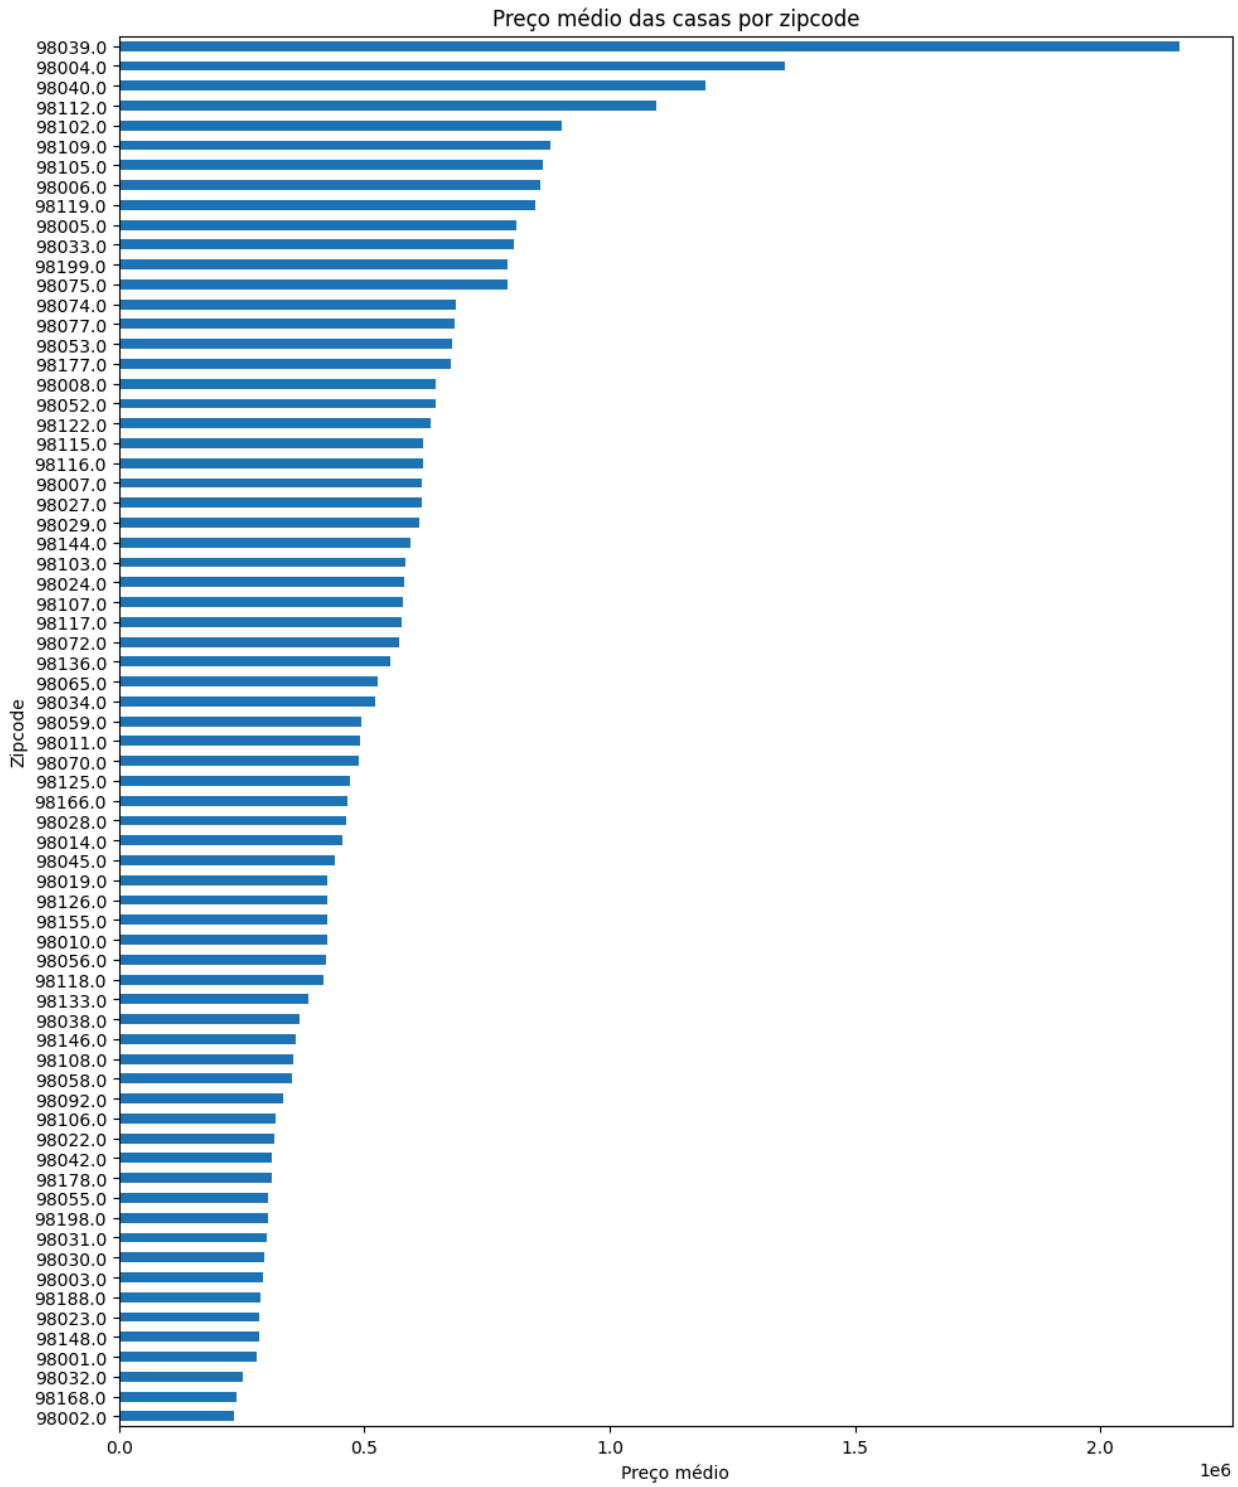

E no segundo gráfico, podemos ver como o preço médio das casas aumenta conforme o percentual de pessoas qualificadas academicamente aumenta, e

como baixos níveis de formação acadêmica levam à concentração de preços menor elevados na região:

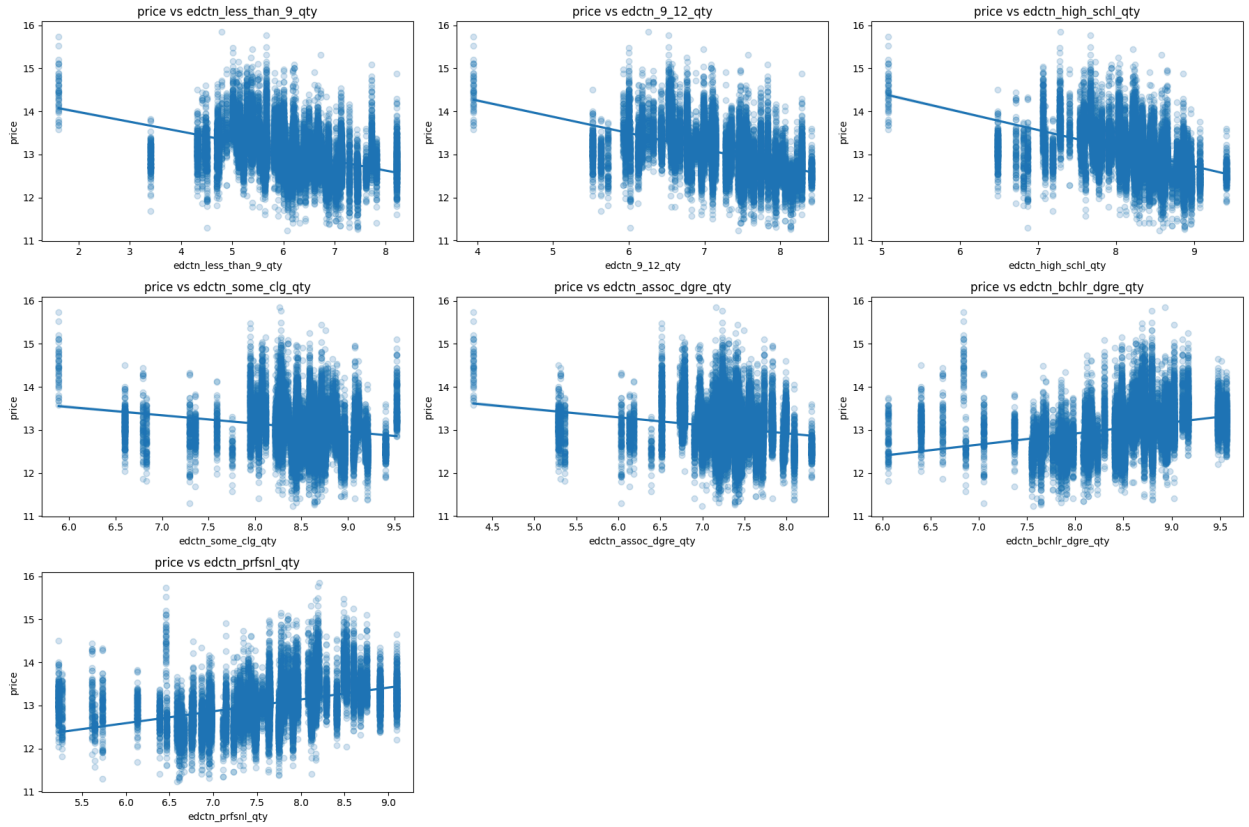

Portanto, é razoável afirmarmos que casas localizadas em bairros nobres, de renda média elevada e alto percentual de pessoas altamente qualificadas academicamente, tendem a ter valores mais altos em comparação à casas localizadas em bairros populares.

Tendo em vista esta constatação seria interessante combinarmos os dois datasets para que os dados socioeconômicas possam enriquecer o aprendizado do modelo, associando o perfil socioeconômico da região em que o imóvel está localizado, com o preço final do imóvel.

Mesclando os datasets (merge)

É possível observar que:

- O dataset de casas possui o zipcode associado ao endereço da casa;

- Todas as regiões descritas no dataset do perfil socioeconômico das regiões também possuem um zipcode associado;

Portanto, a combinação dos dois datasets pode ser feita através do zipcode, deste modo, podemos atrelar um perfil socioeconômico a cada uma das casas tendo como base a região onde ela se encontra.

Depois do merge, podemos dropar a coluna `zipcode`.

Visualização dos dados e observações

Assimetria dos Dados

Após a mescla dos dados, verificamos a distribuição dos dados de algumas colunas através de histogramas:

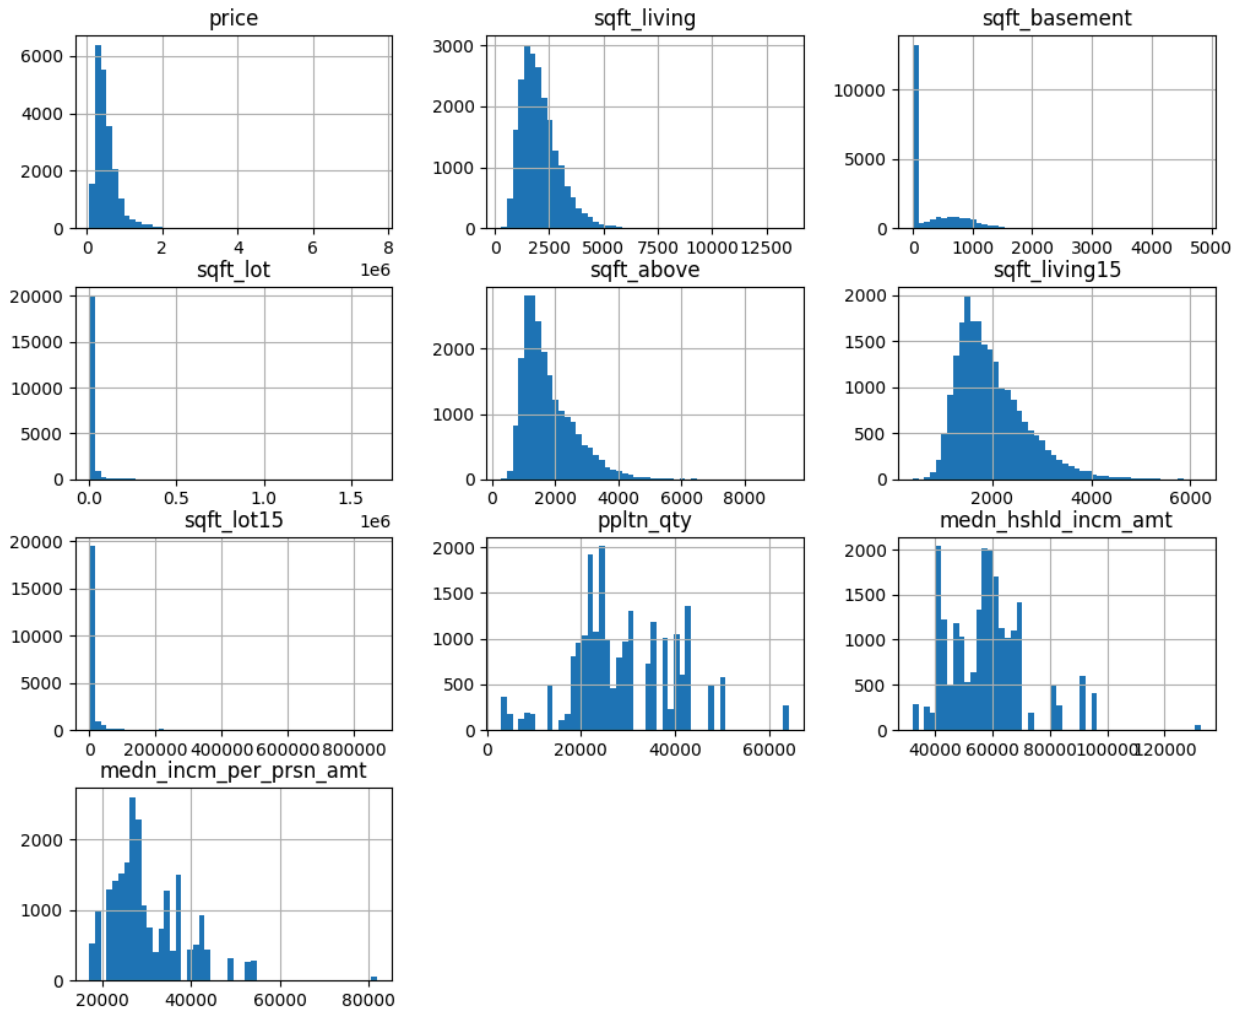

Neste gráfico nota-se assimetria à direita em muitos gráficos: price, sqft_living, sqft_above, sqft_living15, entre outros. Isto nos trás informações interessantes:

- A média dos dados encontra-se mais à esquerda, ou seja, em valores não tão elevados.
- Contudo, existem bastante outliers à direita, ou seja, de valor elevador
- Nota-se uma tendência de assimetria à direita entre os gráficos de preço e de características da casa, o que nos permite afirmar que estas características acompanham o preço da casa.

Outliers

Vamos verificar a presença de outliers no boxplot abaixo:

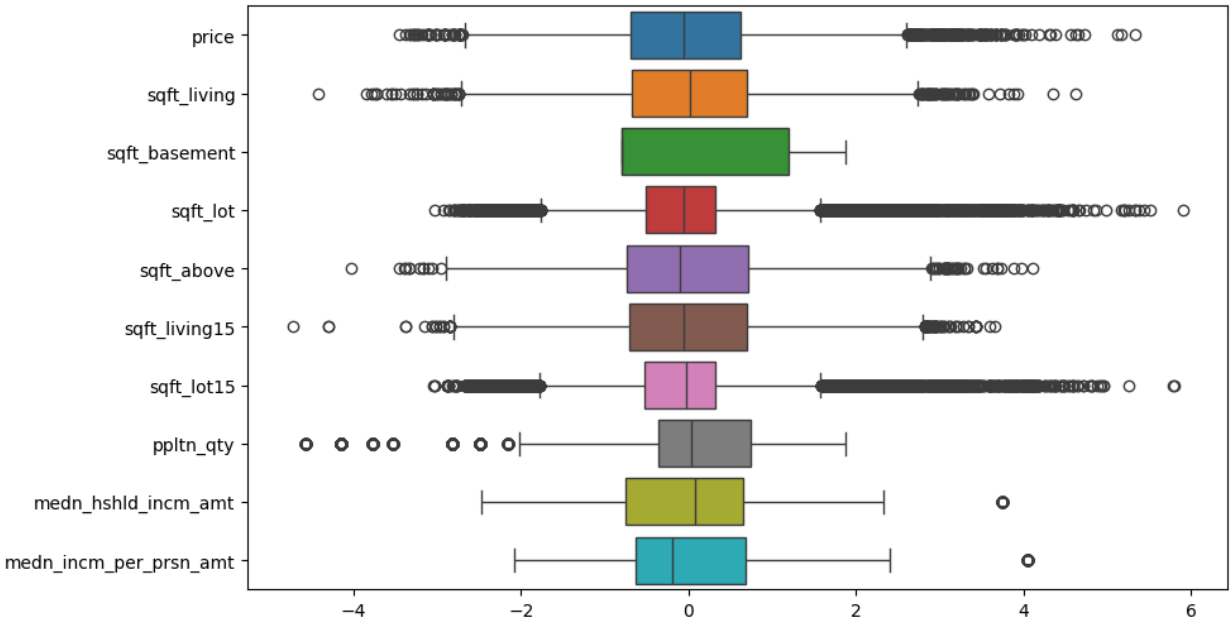

Pela leitura dos gráficos, podemos perceber que:

- Existem muitos outliers, especialmente com o desvio padrão para cima, o que nos diz que existem diversas casas que devem ter ser muito grande e muito caras.

Durante o desenvolvimento do modelo, foi feita uma experiência onde tentamos removers todos os outliers com `z-score > 3.5`. Notamos que o modelo teve um desempenho pior. Uma hipótese que pode explicar este comportamento é que

estes outliers, embora sejam extremos, explicam a tendência de que casas extremamente grandes, como mansões, realmente tem preços extraordinários. E embora sejam valores extremos, é um fato de mercado de que existem casas gigantescas com preços gigantescos.

Correlação

Vamos analisar agora o gráfico de correlação entre preço e as demais variáveis:

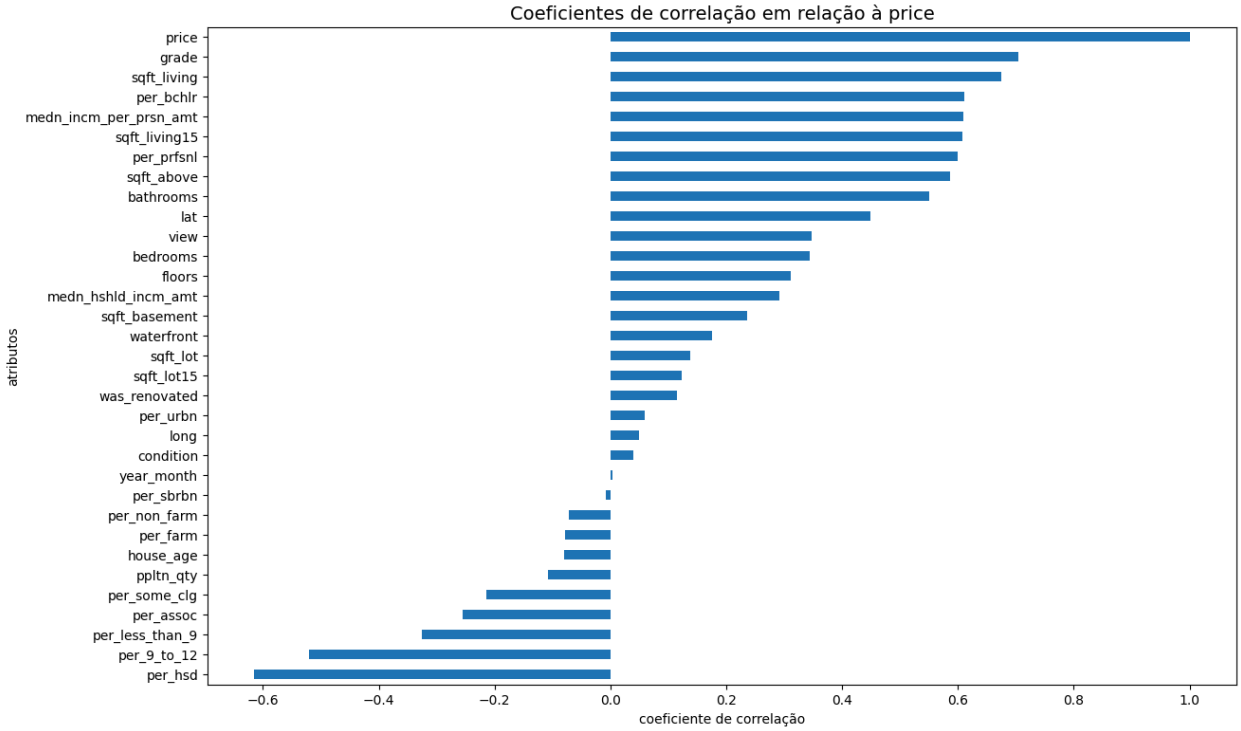

Podemos notar que as variáveis que possuem maior correlação linear com price são:

1. grade
2. sqft_living
3. per_bchlr
4. medn_incm_per_prsn_amt
5. sqft_living15
6. per_prfsnl

7. sqft_above
8. bathroom
9. lat
10. view

Contudo, isto não quer dizer que sejam as melhores features para conseguirmos treinar um modelo de Regressão Linear, visto que muitas delas podem ser redundantes entre si. A seguir, vamos verificar um modo mais assertivo de definição da importância das features.

Importância das Features

Ao utilizarmos o `LassoCV`, que treina o modelo `Lasso` utilizando cross-validation, e extraindo o seus coeficientes que ilustram a importância das features para o modelo, temos a seguinte lista com as dez features melhor rankeadas:

1. waterfront: 0.428011
2. per_bchlr: 0.137412
3. grade: 0.123237
4. medn_incm_per_prsn_amt: 0.093419
5. per_prfsnl: 0.092620
6. per_less_than_9: 0.089748
7. sqft_living: 0.089522
8. sqft_above: 0.083420
9. was_renovated: 0.068285 (feature transformada de yr_renovated)
10. lat: 0.066170

É possível perceber o conjunto das features mais importantes possui uma grande intersecção entre as features correlacionadas linearmente que vimos na seção anterior.

Podemos perceber diversas features que vieram do dataset de informações socioeconômicas, o que é interessante observar, visto que é algo que não é necessariamente óbvio na determinação do preço de uma casa.

Além disso, vemos que casas que possuem acesso a um corpo d’água são muito valorizadas, o que é de se esperar também.

A condição da casa e o seu tamanho também possuem uma grande influência sobre seu valor.