Comunicação com Stakeholders

Sugestão de Apresentação de Slides

Slide 01 - Apresentação da Solução

- A solução tem como objetivo fornecer um **serviço capaz de estimar de forma rápida e com precisão o valor de imóveis** a partir de informações fornecidas pelo usuário.
- Para realizar a predição, o serviço utiliza **características físicas do imóvel e sua localização**.
    - A partir da localização, o modelo integra automaticamente **dados demográficos da região**, enriquecendo a análise e aumentando a precisão das estimativas.

Slide 02 - Descrição do Serviço

- O planejamento prevê o **deployment do serviço na nuvem**, permitindo acesso simples e rápido via internet por aplicações interessadas em consumir o modelo.
- Dessa forma, é possível **integrar facilmente o serviço de predição de preços de imóveis** a diferentes sistemas poupando esforço técnico.
- Casos de uso e clientes em potencial:
    - **Portais imobiliários:** fornecendo ao usuário estimativas rápidas e confiáveis do valor de um imóvel.
    - **Sistemas internos de corretoras:** permitindo avaliações automatizadas com maior agilidade e suporte à tomada de decisão.

Slide 03 — Sobre o Modelo

- A solução utiliza um **modelo de Machine Learning** para estimar o valor de imóveis com base em características físicas do imóvel e em sua localização.

- O modelo foi treinado com **dados históricos de vendas e indicadores socioeconômicos e demográficos regionais**, permitindo gerar estimativas rapidamente e de forma precisa para **apoiar análises e ajudar a determinar preços de imóveis**.

Slide 04 - Estratégia de treinamento

- Para identificar o melhor modelo para a tarefa, foram treinados quatro algoritmos:
  1. Regressão Linear: modelo simples que estima os preços de forma linear; usado como baseline (base de comparação).
  2. Random Forest: conjunto de árvores de decisão que faz previsões pela média das árvores.
  3. Gradient Boosting: constrói árvores em sequência, onde cada uma corrige os erros da anterior.
  4. XGBoost: versão otimizada do Gradient Boosting, eficiente e com ótimo desempenho em dados tabulares; captura relações não lineares.
- A escolha priorizou modelos com bom desempenho em dados tabulares.
- Modelos baseados em árvores (como o XGBoost) tendem a capturar relações mais complexas (não lineares).

Slide 05 - Escolha do Modelo

- Após o treinamento do modelo, foi feito um estudo comparativo dos resultados:

Modelo	R^2	MAE
Linear Regression	0.8427	86563
Random Forest	0.8714	69735
Gradient Boosting	0.9023	66406
XGBoost	0.9084	64072

- Como é possível verificar pela tabela, o XGBoost foi escolhido por ter melhor desempenho e menor erro.

Slide 06 - Sobre o Modelo

- Métricas do modelo:
  - $R^2 : 90\%$
    - O modelo explica 90% da variação dos preços em torno da média, indicando ótimo desempenho.
  - $MAE : 64000$
    - Ou seja, a margem de erro do modelo é de cerca de 64000 (USD?).

Slide 07 - Principais Variáveis

- O gráfico apresenta, no eixo vertical, as variáveis mais importantes para o modelo XGBoost.
- Principais conclusões:
  - **Tamanho do imóvel e do terreno** (área construída e área do lote) são os fatores com maior impacto no preço.
    - Em geral, quanto maiores essas áreas, maior tende a ser o valor do imóvel.
  - **Idade do imóvel:** imóveis mais antigos tendem a apresentar preços menores.
  - **Fatores demográficos:** renda per capita e nível de qualificação acadêmica/profissional da região também influenciam o preço.
    - Quanto maior a proporção de pessoas altamente qualificadas, maior tende a ser o valor dos imóveis na região.

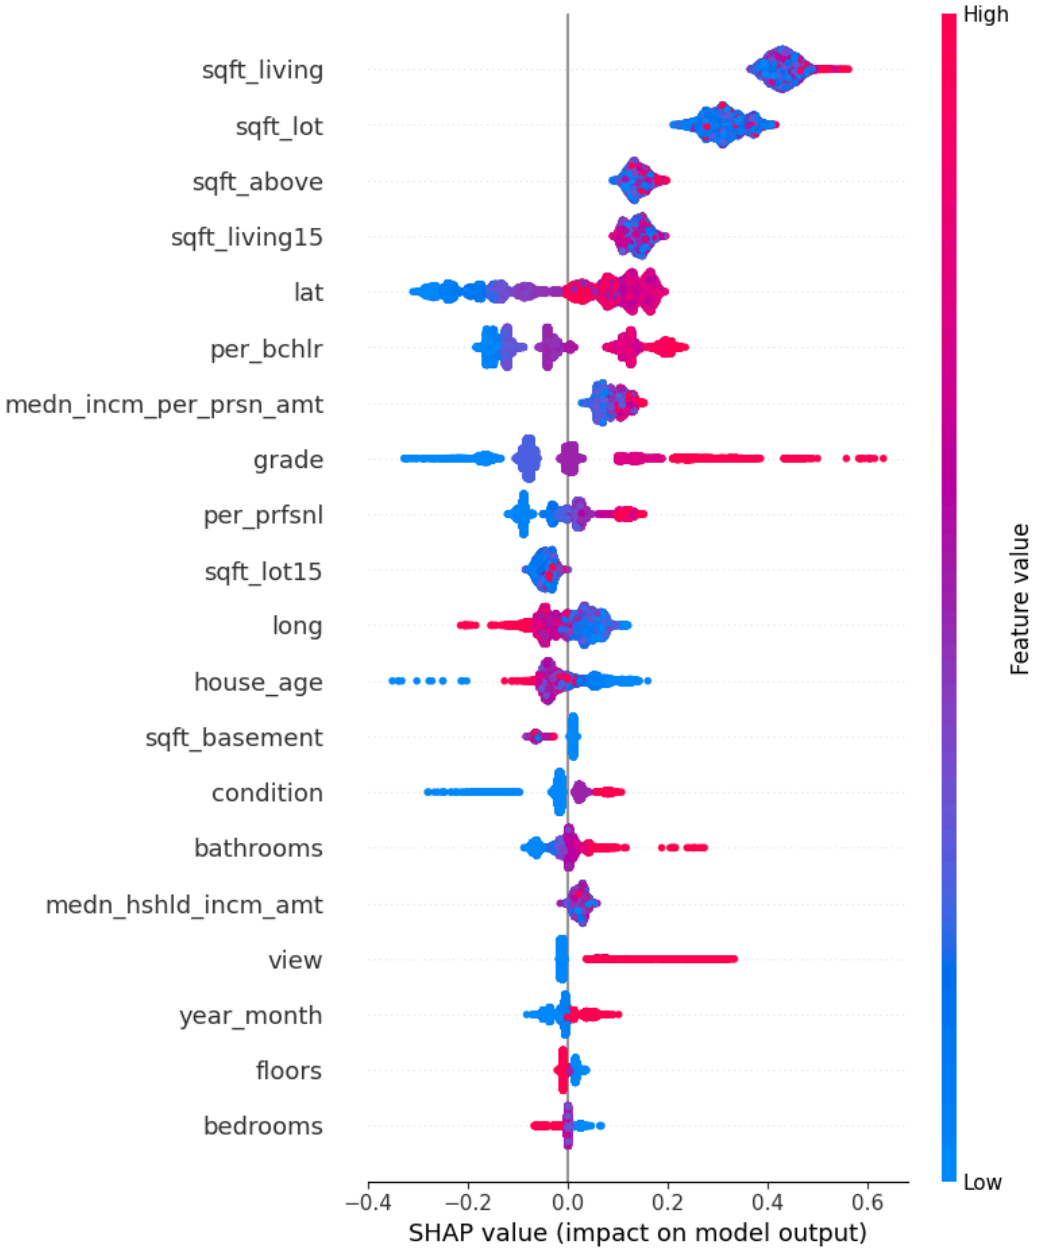

Slide 08 - Como o modelo determina um preço

- Neste slide, vemos como o modelo chega ao preço previsto ao decompor a contribuição de cada variável.

Observações principais

- **Preço acima da média:** este imóvel foi estimado com valor superior à média do conjunto de dados.

- **Fatores que mais aumentaram o preço:** tamanho da casa e do terreno (principais influenciadores do valor final).
- **Outros impactos positivos (menores):** tamanho das casas na vizinhança, área construída acima do solo e renda per capita da região.
- **Fatores que reduziram o preço:** percentual de pessoas altamente qualificadas abaixo da média, indicando um contexto socioeconômico menos favorável.
- **Reduções adicionais:** condição de conservação mediana e baixa quantidade de banheiros.

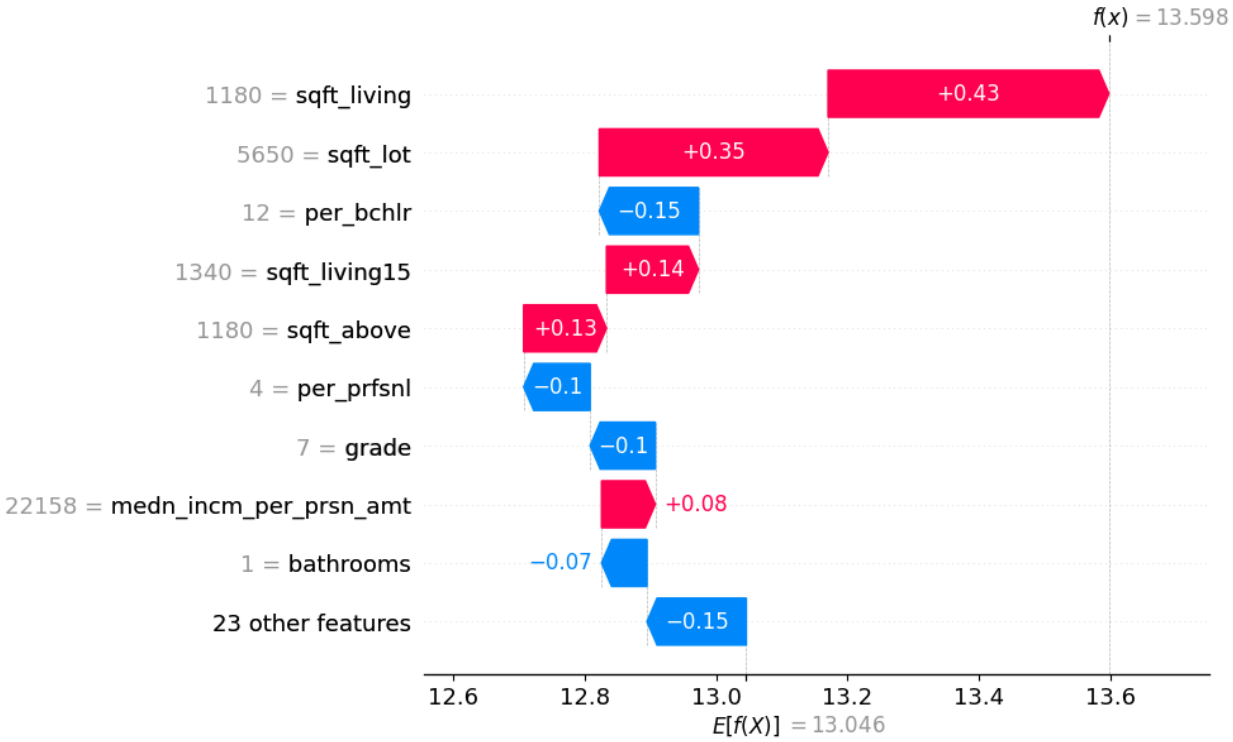

Slide 09 - Observações sobre limitações do modelo

Viés de introduzida por feature como grade e condition

- Pela análise das características mais importantes para o modelo, foi possível perceber a presença de qualidades subjetivas, que estão atreladas à interpretação da avaliação feitas por um corretor;
    - Features como condição de conservação da casa e sua nota.

- Tais features podem causar um viés na análise do modelo, dado que a avaliação feita por uma pessoa é subjetiva - diferentes pessoas poderiam avaliar o estado da casa utilizando notas diferentes;

Quantidade de features

- Em uma futura iteração da solução, podemos explorar formas de reduzir a quantidade de features que o usuário precisa inserir para fazer a predição, buscando melhorar a experiência do usuário, que poderia se frustrar o rejeitar o uso da ferramenta devido à necessidade de preencher uma grande quantidade de campos.